



IMPLEMENTACIÓN DE MODELO DE REDES NEURONALES CONVOLUCIONALES PARA CLASIFICACIÓN DE IMÁGENES HIPERESPECTRALES USANDO TRANSFORMADA WAVELET

Brayan Yesid Quintero Santander
Ingeniería de Sistemas, Universidad Industrial de Santander, Colombia,
brayan2221707@correo.uis.edu.co

Cristhian Camilo Rey Rueda
Ingeniería de Sistemas, Universidad Industrial de Santander, Colombia,
cristhian2200190@correo.uis.edu.co

Juan David Toloza Parada
Ingeniería de Sistemas, Universidad Industrial de Santander, Colombia,
juan2221067@correo.uis.edu.co

Hoover Fabián Rueda Chacón, PhD.
Ingeniería de Sistemas, Universidad Industrial de Santander, Colombia,
hfarueda@uis.edu.co

Resumen

Introducción: La clasificación de imágenes hiperespectrales (HSI) mediante redes neuronales convolucionales (CNN) es un área de gran interés en la visión por computadora. Sin embargo, los métodos utilizados para esta tarea no integran eficazmente las características espectrales y espaciales. **Objetivo:** Desarrollar un modelo CNN que utilice la transformada Wavelet para extraer de manera eficiente dichas características, que clasifique imágenes HSI de manera eficiente, mejorando la precisión en comparación con enfoques tradicionales como SVMs, 2D-CNNs y 3D-CNNs. **Metodología:** Se utilizó el dataset de Pavía, generando parches de 12x12x3 mediante análisis factorial y aumento de datos. Estos parches fueron utilizados como entrada en SpectralNET (Chakraborty & Trehan, 2021), la cual fue entrenada y evaluada. **Resultados:** SpectralNET mostró un excelente rendimiento en las fases de entrenamiento y validación. Su capacidad para extraer tanto características espectrales como espaciales le permite destacar en la clasificación de imágenes HSI. **Conclusiones:** SpectralNET mejora la precisión de clasificación y reduce la carga computacional en comparación con otros métodos. La combinación de transformadas Wavelet y 2D CNN demuestra ser una solución eficaz y de buen rendimiento para la clasificación de imágenes hiperespectrales.

Palabras clave: Imágenes hiperespectrales, Clasificación espectral, Redes neuronales convolucionales, Transformada Wavelet.

1. Introducción

Las imágenes hiperespectrales (HSI, por sus siglas en inglés) capturan información de una porción del espacio en múltiples bandas del espectro electromagnético, a diferencia de las imágenes RGB convencionales que solo utilizan tres bandas. Esto permite revelar características de los materiales que no son perceptibles al ojo humano. Del fenómeno descrito anteriormente surge el concepto de “firma espectral”, representativa para cada material, y que se obtiene al analizar cómo dicho material refleja o absorbe la luz, también conocida como reflectancia (Amigo, 2020).

La clasificación de imágenes hiperespectrales es crucial en una amplia variedad de campos, como la agricultura, la geología y la vigilancia ambiental. Permite identificar con precisión tipos de cultivos, determinar el estado de salud de las plantas, detectar contaminantes en cuerpos de agua, o incluso identificar minerales y componentes del suelo.

Sin embargo, el procesamiento de este tipo de datos presenta desafíos significativos debido a la alta dimensionalidad y la complejidad de las firmas espectrales, lo que exige el desarrollo de métodos avanzados de análisis.

Este artículo presenta el proceso de

implementación de un modelo de redes neuronales convolucionales (CNN) que utiliza la transformada Wavelet para extraer de manera eficiente la información contenida en un cubo espectral. La aplicación de estas técnicas avanzadas optimizó el procesamiento de las imágenes, permitiendo al modelo identificar con alta precisión diversos objetos o superficies, como casas y cuerpos de agua, y de esta manera realizar una clasificación detallada de las características presentes en la imagen.

2. Metodología

2.1 Descripción del modelo

Las redes neuronales convolucionales (CNN) 2D se emplean comúnmente para procesar imágenes, ya que están diseñadas para trabajar sobre datos en dos dimensiones. Se denominan “bidimensionales” porque su núcleo o *kernel* se desplaza a lo largo de las dos dimensiones espaciales de la imagen, extrayendo de manera eficiente las características espaciales clave (Zheng, Feng, Bai & Zhang, 2020).

Esta capacidad de capturar patrones y relaciones espaciales en los datos es una de las principales ventajas de las CNNs, superando a otros tipos de redes que no están optimizadas para este tipo de tareas (Ge, Cao,

Li & Fu, 2020). Una CNN básica puede representarse matemáticamente como la suma ponderada de vecinos más próximos con un sesgo constante añadido.

Dado un vector de entrada X con las etiquetas correspondientes Y del espacio R^n , en la Ecuación 1 se representa cada etiqueta y_i , como el producto de cada muestra x_i con el peso w_j definido por el kernel de tamaño N_i (i vecinos).

$$y_i = \sum_{j \in N_i} w_j x_j \quad (1)$$

La Ecuación 1 puede ser considerada como la convolución de X y el *kernel* W , que puede reescribirse como $Y = X * W$, esto se llama capa de convolución. La salida de las capas de convolución suele ser grande y necesita ser agrupada antes de alimentarla en las siguientes capas. Las capas de agrupación (del inglés *Pooling Layer*), se colocan entre capas de convolución para realizar una operación de filtrado y reducir el número de salidas.

2.2 Conjunto de datos hiperespectrales utilizados

El experimento fue realizado utilizando el dataset de la ciudad de Pavía (Graña, Veganzons, & Ayerdi, 2021), un conjunto de datos ampliamente utilizado en el procesamiento de imágenes hiperespectrales. Este dataset consta de un cubo espectral con 1,096 filas, 715 columnas y 102 bandas espectrales, cubriendo un rango de longitud de

onda de 430 a 860 nm, lo que lo convierte en una fuente de datos rica y variada para la clasificación espectral.

El entorno de trabajo seleccionado para llevar a cabo el entrenamiento fue Google Colab, aprovechando su ejecución gratuita en la GPU T4, que permitió reducir significativamente el tiempo de procesamiento y entrenamiento del modelo. Esta elección fue clave para acelerar los experimentos, dado que las tareas de clasificación en imágenes hiperespectrales pueden ser computacionalmente intensivas.

2.3 Parámetros de entrenamiento de la red

Basándonos en estudios previos y en la literatura científica relevante, se decidió configurar el optimizador de descenso de gradiente estocástico (SGD, por sus siglas en inglés) con una tasa de aprendizaje de 0.01 y un momentum de 0.9. Estas configuraciones fueron seleccionadas porque ofrecieron un buen equilibrio entre la velocidad de convergencia y la estabilidad durante el entrenamiento, evitando tanto la convergencia prematura como la oscilación excesiva del gradiente. La combinación de estos parámetros se ha demostrado eficaz para optimizar la minimización del error durante el proceso de ajuste de los pesos del modelo.

Para mejorar la eficiencia del entrenamiento y reducir el tiempo de procesamiento, se optó por extraer parches con dimensiones de 12x12 píxeles y un número reducido de 3 bandas

espectrales por parche. Esta reducción en la cantidad de bandas fue motivada por la necesidad de disminuir la complejidad computacional, sin comprometer significativamente la información espectral útil para la clasificación. Esta estrategia ha sido empleada en varios estudios para encontrar un equilibrio entre la dimensionalidad de los datos y el rendimiento del modelo.


El modelo fue entrenado durante un total de 10 épocas, un número que se estimó suficiente

para lograr una convergencia del modelo sin llegar a un sobreajuste. Cada época representó un ciclo completo de entrenamiento donde el modelo ajustó sus parámetros para minimizar la función de pérdida en el conjunto de entrenamiento.

En la Figura 1, observamos las firmas espectrales de cada una de las clases de nuestro conjunto de datos contaba con 9 clases etiquetadas.

Figura 1

Firmas espectrales correspondientes a las 9 clases etiquetadas en el dataset. En la imagen, se muestran las firmas espectrales asociadas a cada clase, lo que permite visualizar las diferencias y patrones característicos en las distintas categorías del conjunto de datos.



Fuente: Elaborada por autores

2.4 Preprocesamiento de los datos

El cubo hiperespectral que utilizamos como entrada a nuestro modelo tenía inicialmente dimensiones de 1096 x 715 x 10. Tras

completar el paso de análisis factorial, se extrajeron parches 3D superpuestos de dimensiones 12x12x3 del cubo hiperespectral preprocesado. El tamaño de los parches de

12x12 se determinó mediante experimentación con el fin de optimizar la precisión global del modelo.

Posteriormente, los parches fueron sometidos a un proceso de aumento de datos, en el que se aplican rotaciones, incrementando el número de muestras de entrada en un 40%. El conjunto de datos resultante, tras el análisis factorial y el aumento de datos, fue utilizado como entrada en nuestro modelo


SpectralNET. En la Figura 2 podemos observar detalladamente la arquitectura del modelo implementado.

2.5 Fundamentos Transformada Wavelet

El uso de la transformada Wavelet abre el camino hacia las CNN de múltiples resoluciones, donde la convolución es realizada por un par de *kernels* K_{low} y K_{high} , los cuales generan X_{low} y X_{high} .

Figura 2

El cubo de HSI de entrada se preprocesa mediante Análisis Factorial (FA) para reducir su dimensión a 3 componentes (*factores*). Posteriormente, se extraen parches de la imagen y se someten a un proceso de aumento de datos, que luego se utilizan como entrada al modelo *SpectralNET*. Este modelo aplica una descomposición Wavelet en 4 niveles. Utiliza kernels de 3x3 con padding de 1x1 y stride de 2 para reducir el mapa de características, agregando las características transformadas por canal. Para mitigar el desvanecimiento del gradiente, se emplean atajos mediante convoluciones 1x1. Finalmente, se aplica un pooling global antes de enviar la salida a las capas completamente conectadas con dropout.



Fuente: Tomada de Chakraborty y Trehan (2021).

La CNN de múltiples resoluciones realiza una descomposición jerárquica de $X_{low,t}$ en $X_{low,t+1}$ y $X_{high,t+1}$ con *kernels* diferentes en cada paso t (Cheng, Jiang, Han, Wang & Torr,

2023). En *SpectralNet*, el *kernel* $K_{high,t}$ se basa en las ondas Haar (del inglés *Haar Wavelet*), mientras que $K_{low,t}$ corresponde a una función de escalado. Las ondas Haar en

2D utilizan cuatro *kernels* específicos: $f_{L,L}$, $f_{L,H}$, $f_{H,L}$, $f_{H,H}$, que se emplean para llevar a cabo la transformada *Wavelet* (Fujieda, Takayama, & Hachisuka, 2018). Estos kernels se describen por la Ecuación (2) como:

$$\begin{aligned} f_{L,L} &= \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix} & f_{L,H} &= \begin{bmatrix} -1 & -1 \\ 1 & 1 \end{bmatrix} \\ f_{H,L} &= \begin{bmatrix} -1 & 1 \\ -1 & 1 \end{bmatrix} & f_{H,H} &= \begin{bmatrix} 1 & -1 \\ -1 & 1 \end{bmatrix} \end{aligned} \quad (2)$$

En un parche de la imagen hiperespectral al aplicarle la transformada de Haar, el valor de la posición espectral (i,j) puede expresarse mediante la Ecuación (3) como:

$$\begin{aligned} Haar(i,j) &= x(2i - 1, 2j - 1) \\ &\quad + x(2i - 1, 2j) \\ &\quad + x(2i, 2j - 1) + x(2i, 2j) \end{aligned} \quad (3)$$

El parche de la HSI es tomado como entrada y descompuesto por la transformada *Wavelet* en sub-bandas, después estas sub-bandas son enviadas a una capa de convolución para que el modelo aprenda de las características espectrales y su localización. Posteriormente, una parte de la sub-banda es descompuesta nuevamente en la siguiente capa mediante la transformada *Wavelet*, que posteriormente se envía a la capa de convolución.

Este proceso de descomposición se repite en cada capa, lo que permite que la red neuronal convolucional aprenda progresivamente las características espectrales y espaciales del parche hiperespectral. De esta manera, la

CNN aprovecha tanto la información espacial como la espectral para una mejor representación y clasificación de los datos.

3. Resultados

El rendimiento del modelo se presenta en la Figura 4, donde se muestran las gráficas del comportamiento del *accuracy* y la función de pérdida (del inglés *loss function*), a lo largo de las diferentes épocas.

Las métricas resultantes pueden observarse en la Figura 3, las cuales ofrecen una evaluación precisa del desempeño del modelo tanto durante la fase de entrenamiento como en la etapa de prueba con los datos de validación, las fórmulas que se usan en cada de las 3 métricas se pueden observar a continuación.

	POSITIVE	NEGATIVE
POSITIVE	TP	FN
NEGATIVE	FP	TN

$$\begin{aligned} Precision &= \frac{TP}{TP + FP} & Recall &= \frac{TP}{TP + FN} \\ Accuracy &= \frac{TP + TN}{TP + FP + FN + TN} \\ F1\ Score &= 2 \times \frac{Precision \times Recall}{Precision + Recall} \end{aligned} \quad (4)$$

Figura 3

Métricas que se tomaron en cuenta para la evaluación del modelo: precisión, recall y F1-score, desglosadas por cada clase.


	precision	recall	f1-score	support
0	1.00	1.00	1.00	660
1	1.00	1.00	1.00	76
2	1.00	1.00	1.00	31
3	1.00	1.00	1.00	27
4	1.00	1.00	1.00	66
5	1.00	1.00	1.00	92
6	1.00	1.00	1.00	73
7	1.00	1.00	1.00	428
8	1.00	1.00	1.00	29
accuracy			1.00	1482
macro avg	1.00	1.00	1.00	1482
weighted avg	1.00	1.00	1.00	1482

La partición de los datos se realizó dividiendo el conjunto de píxeles de la imagen hiperespectral en un 80% para entrenamiento y un 20% para prueba, garantizando así un

adecuado balance entre la cantidad de datos usados para ajustar los parámetros del modelo y un conjunto suficientemente representativo para evaluar su capacidad de generalización. Tal como se observa en la Figura 4, el modelo alcanzó un rendimiento notable, logrando altos niveles de *accuracy* tanto en el entrenamiento como en la validación. Las curvas de *accuracy* y *loss* revelan una mejora progresiva a lo largo de las épocas, lo que sugiere que el modelo está convergiendo de manera efectiva hacia una solución óptima.

Figura 4

Gráficas de rendimiento del modelo. En la parte izquierda se presenta el comportamiento del modelo en términos de precisión (accuracy) y pérdida (loss) utilizando parches de entrada de dimensiones 12x12x3. En la parte derecha se muestra el rendimiento después del aumento de datos. Este enfoque permitió optimizar tanto la precisión como la reducción de la pérdida.



Además, la implementación de técnicas de aumento de datos (*data augmentation*)

contribuyó significativamente a mejorar el rendimiento del modelo, reflejando una mejor

generalización y una reducción del riesgo de sobreajuste (*overfitting*).

La mejora en el rendimiento es evidente en la mayor estabilidad observada en las gráficas, donde se aprecia una disminución más rápida de la pérdida y un aumento más consistente del *accuracy* a lo largo de las épocas. Esto indica que el modelo no solo logra adaptarse correctamente a los datos de entrenamiento, sino que también mantiene un desempeño robusto y confiable cuando se enfrenta a datos no vistos previamente.

Estas observaciones resaltan la importancia de técnicas como el *data augmentation* para promover un entrenamiento más eficaz y equilibrado, evitando que el modelo se ajuste demasiado a los datos específicos del conjunto de entrenamiento y favoreciendo una generalización más sólida en diferentes escenarios de testeo.

En la Figura 5 se muestra una comparación visual entre los resultados de predicción obtenidos por el modelo y el *ground truth*. En el panel izquierdo, se presenta una imagen pseudo-RGB generada a partir de tres bandas espectrales seleccionadas del cubo hiperespectral. En el panel central, se

encuentra la referencia del *ground truth*, mientras que el panel derecho muestra las predicciones del modelo. A través del uso de colores, se destacan las áreas correctamente clasificadas, y se identifican las pocas diferencias existentes entre el *ground truth* y las predicciones. Esta figura facilita la visualización clara de las regiones correctamente identificadas por el modelo, permitiendo evaluar su precisión en la clasificación espectral.

4. Discusión

Además de la implementación del modelo SpectralNet, se logró un manejo apropiado para los datos que permitió modificar y mejorar el preprocesamiento, lo que ayudó a reducir el riesgo de sobreajuste, especialmente considerando la cantidad limitada de parámetros en el conjunto de datos utilizado.

También se aplicaron predicciones por lotes (del inglés *batch predictions*), para optimizar el rendimiento y aligerar la carga computacional durante el proceso de predicción. Una de nuestras principales limitaciones fue el tamaño del conjunto de datos, que acota el análisis a un número limitado de parámetros. Durante la implementación nos enfrentamos a un desafío relacionado con el tamaño de los parches.


Figura 5

A la izquierda se muestra una imagen pseudo-RGB de la ciudad de Pavía, generada a partir de un conjunto de datos hiperespectrales. En el centro se presenta el ground truth, con las


clases clasificadas correctamente. A la derecha, se observa la predicción del modelo implementado, que reproduce con alta precisión las diferentes clases presentes en el ground truth, evidenciando la efectividad del modelo en la clasificación de datos hiperespectrales.



Pavia pseudo-RGB



Pavia ground truth



Pavia prediction

Optamos por el método de prueba y error para determinar el tamaño óptimo, ya que:

- Cuando seleccionamos parches más pequeños, experimentamos problemas de memoria en Google Colab notebooks, impidiendo así continuar con el entrenamiento del modelo.
- En caso de seleccionar un tamaño de parche mayor al utilizado, el modelo se veía limitado debido a la reducción en la cantidad de datos de entrada, lo que aumentaba el riesgo de sobreajuste.

5. Conclusiones

En este artículo se presentó una implementación efectiva de la arquitectura

SpectralNet para la clasificación de imágenes hiperespectrales. Los resultados demuestran que la combinación de estas técnicas de preprocesamiento mejoran significativamente el rendimiento del modelo, logrando adaptarse eficientemente al conjunto de datos hiperespectrales.

Las métricas obtenidas, particularmente en términos de precisión y capacidad predictiva, son notablemente altas y corresponden fielmente a las etiquetas proporcionadas en el dataset. Estos hallazgos sugieren que *SpectralNet* es una arquitectura prometedora para tareas de clasificación de imágenes hiperespectrales. Futuras líneas de investigación podrían explorar la aplicación de

este enfoque a otros conjuntos de datos y tareas de aprendizaje automático.

Referencias

Amigo, J. M. (2020). Hyperspectral and multispectral imaging: setting the scene. En J. M. Amigo (Ed.), *Hyperspectral Imaging* (pp. 3-16). Países Bajos: Elsevier

Chakraborty, T., & Trehan, U. (2021). SpectralNET: Exploring Spatial-Spectral WaveletCNN for Hyperspectral Image Classification. *arXiv*, 2104(00341v1), 1-7. Recuperado en 10 de septiembre de 2024, de <https://arxiv.org/abs/2104.00341>

Cheng, M.-M., Jiang, P.-T., Han, L.-H., Wang, L., & Torr, P. (2023). Deeply explain CNN via hierarchical decomposition. *International Journal of Computer Vision*. Recuperado de https://mftp.mmcheng.net/Papers/23IJCV_CN_NasDT.pdf

Fujieda, S., Takayama, K., & Hachisuka, T. (2018). Wavelet convolutional neural networks. *arXiv preprint*, arXiv:1805.08620

Ge, Z., Cao, G., Li, X., & Fu, P. (2020). Hyperspectral image classification method based on 2D–3D CNN and multibranch feature fusion. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, 13, 5776-5788.

Graña, M., Veganzons, M. A., & Ayerdi, B. Hyperspectral Remote Sensing Scenes. Universidad del País Vasco. https://www.ehu.eus/ccwintco/index.php/Hyperspectral_Remote_Sensing_Scenes#Pavia_Centre_scene

J. Zheng, Y. Feng, C. Bai, and J. Zhang. (2020). Hyperspectral image classification using mixed convolutions and covariance pooling. *IEEE Transactions on Geoscience and Remote Sensing* (pp. 1-13).